

Instalación y configuración

Apache Cassandra - Bases de datos II

Alberto Díaz Álvarez (<alberto.díaz@upm.es>)

Departamento de Sistemas Informáticos

Escuela Técnica superior de Ingeniería de Sistemas Informáticos

License CC BY-NC-SA 4.0

Introducción

Instalación

Cassandra funciona en muchos sistemas operativos diferentes

- GNU/Linux, Windows, Mac OS X, FreeBSD, Solaris, etc.
- Nos centraremos en GNU/Linux, concretamente en Ubuntu GNU/Linux 22.04
- Bueno, y en Docker, porque es muy cómodo

Prerequisitos:

- La última versión de Java 8 o Java 11 (`java -version`)
 - Valen tanto la *OpenJDK* como la *Oracle Java Standard Edition*
- Python 3.6 o superior (`python --version`)
 - Esto es por si queremos ejecutar `cqlsh` , la consola de Cassandra
- Docker (si queremos instalar mediante Docker, claro)

Despliegue mediante Docker

Instalación y despliegue con la imagen de **docker**

Este es el medio más sencillo de instalación:

- Descargar (**pull**) la imagen de Docker de Cassandra:

```
docker pull cassandra:latest
```

- Iniciar un contenedor a partir de la imagen descargada:

```
docker container run -d cassandra --name cassandra_n1
```

- Conectarse al contenedor para interactuar con Cassandra mediante **cqlsh**

```
docker exec -it cassandra_n1 cqlsh
```

Y ya estaría

Creando un clúster de tres nodos (I)

Vamos a comenzar creando una red para los contenedores de Cassandra:

```
docker network create cassandra
```

- No es necesario, pero nos permite acceder a los puertos del contenedor sin exponerlos en el host

Ahora, crearemos el primer nodo de nuestro clúster de la manera habitual:

```
docker container run -d --name cassandra_n1 --network cassandra cassandra
```

Y para este nodo obtendremos su dirección IP:

```
NODE1=$(docker inspect --format="{{ .NetworkSettings.Networks.cassandra.IPAddress }}" cassandra_n1)
```

Creando un clúster de tres nodos (II)

Con esta IP, crearemos el segundo nodo y con ambas IPs el tercero:

```
docker container run -d --name cassandra_n2 --network cassandra -e CASSANDRA_SEEDS="$NODE1" cassandra
NODE2=$(docker inspect --format="{{ .NetworkSettings.Networks.cassandra.IPAddress }}" cassandra_n2)
docker container run -d --name cassandra_n3 --network cassandra -e CASSANDRA_SEEDS="$NODE1,$NODE2" cassandra
```

Ahora, vamos a comprobar el estado de los tres nodos (hay que esperar un poco)

```
docker exec -it cassandra_n1 nodetool status
```

Tras un rato, deberíamos ver algo tan bonito como esto:

```
Datacenter: datacenter1
=====
Status=Up/Down
|/ State=Normal/Leaving/Joining/Moving
--  Address      Load       Tokens     Owns (effective)  Host ID                               Rack
UN  172.18.0.4    70.24 KiB   16         76.0%             1c79f250-68e0-41d4-b492-dfe77b78907b  rack1
UN  172.18.0.3    70.24 KiB   16         59.3%             c15431bb-cb4f-4efb-806a-78b004e91a4c  rack1
UN  172.18.0.2    109.39 KiB  16         64.7%             241f0aa1-d4c0-46d9-bd6b-747247eecda9  rack1
```

Creando un clúster de tres nodos (y III)

Ahora podemos conectarnos a cualquiera de los nodos para ejecutar `cqlsh` :

```
docker exec -it cassandra_n1 cqlsh
```

Y ya podemos empezar a trabajar con el clúster igual que con un sólo nodo:

```
cqlsh> CREATE KEYSPACE test WITH replication = {  
...     'class': 'NetworkTopologyStrategy',  
...     'replication_factor': 3  
... };  
cqlsh> DESCRIBE KEYSPACES;  
  
system          system_distributed  system_traces  system_virtual_schema  
system_auth     system_schema      system_views   test  
  
cqlsh>
```


Más allá del despliegue local

Un clúster de Cassandra puede ser un despliegue en un mismo centro de datos

- En una máquina o en varias máquinas repartidas a lo largo de la misma red

Sin embargo, soporta el despliegue en múltiples centros de datos

- A efectos del sistema cliente, siempre se ve una única instancia de Cassandra
- Internamente, Cassandra se encarga de la replicación de datos entre centros de datos
- Y de la comunicación entre nodos, independientemente de su localización

Despliegue en Ubuntu GNU/Linux

Instalación de prerequisites

Comenzaremos con la actualización de los repositorios y paquetes de ubuntu:

```
$ sudo apt update && sudo apt upgrade -y
```

Tras ello, instalaremos la última versión de Java 11:

```
$ sudo apt install openjdk-11-jdk -y
```

No hará falta instalar Python, ya que viene instalado por defecto en Ubuntu GNU/Linux 22.04

```
$ python3 --version  
Python 3.10.6
```

Instalación del paquete de Cassandra

Primero, añadiremos el repositorio de Cassandra a la lista de repositorios de apt:

```
$ echo "deb http://www.apache.org/dist/cassandra/debian 40x main" | \
sudo tee -a /etc/apt/sources.list.d/cassandra.sources.list
```

Y ahora, añadiremos la clave pública de Cassandra:

```
$ wget -q -O - https://www.apache.org/dist/cassandra/KEYS | \
sudo tee /etc/apt/trusted.gpg.d/cassandra.asc
```

Por último, tras actualizar los índices de nuevo, instalaremos Cassandra

```
sudo apt update && sudo apt install cassandra -y
```

Comprobación de que el nodo está funcionando

No debería ser necesario reiniciar el sistema, el demonio de cassandra se iniciará automáticamente

Para comprobar que está corriendo, basta con comprobar el estado del servicio:

```
$ sudo systemctl status cassandra
```

Deberíamos obtener algo como esto:

```
• cassandra.service - LSB: distributed storage system for structured data  
  Loaded: loaded (/etc/init.d/cassandra; generated)  
  Active: active (running) since Tue 2023-03-16 03:25:52 UTC; 1min 32s ago  
  ...
```

Conenctándonos al nodo

Podemos comprobar el estado del nodo (o del clúster si hay varios nodos conectados) con `nodetool`:

```
$ sudo nodetool status
```

Para conectarnos, al clúster basta con hacer uso de `cqlsh`:

```
$ cqlsh
```

Esto nos conectará al nodo por defecto en la máquina que se ejecuta el comando

Sobre el funcionamiento

Configuración

La configuración de Apache Cassandra se encuentra en el archivo `cassandra.yaml`

- Los ajustes comunes incluyen el tamaño del heap, la dirección IP de escucha y la compresión de datos
- Algunos cambios en la configuración requerirán un reinicio del nodo

Ajustes de memoria

La memoria heap es la usada para almacenar datos en caché y procesar consultas

- Es importante ajustarla para equilibrar rendimiento y estabilidad del nodo:
 - Demasiada: Latencia adicional y mayor probabilidad de fallos
 - Muy poca: Funcionamiento incorrecto y bajo rendimiento

La herramienta `nodetool`

Herramienta de línea de comandos para administrar un clúster de Cassandra

- Permite realizar tareas de diagnóstico y mantenimiento en un nodo individual o en todo el clúster

Ejemplos de uso de `nodetool`

- `nodetool status` : Estado de un nodo y los datos de replicación del clúster
- `nodetool repair` : Repara datos inconsistentes en un nodo o todo el clúster
- `nodetool snapshot` : Captura una instantánea de un nodo o todo el clúster
- `nodetool cfstats` : Estadísticas de rendimiento de una tabla en particular

Gracias